

Maestría en Ciencia de Datos

Departamento de Matemática y Ciencias

Predicción del incumplimiento de las metas externas en los programas del FMI: un enfoque basado en el aprendizaje automático.

Augusto Alejandro Comisso

Directora: Dra. Marcela Svarc

2026



Resumen

Resumen. El estudio evalúa el rendimiento fuera de muestra del modelo de aprendizaje automático *Random Forest* (RF) en la predicción del incumplimiento de los *External Quantitative Performance Criteria* (QPCs) o metas externas de los programas de préstamo del Fondo Monetario Internacional (FMI). Para el entrenamiento y testeo del modelo se ha utilizado la base de datos *Monitoring of Fund Arrangements* (MONA) del FMI. El modelo se entrenó con información entre 2003 y 2021, y se testeó su capacidad de predicción para el período 2022-2024. El modelo logra un rendimiento $F1_w$ de 0,87 para los 38 países deudores en el set de test, de 0,88 para los cuatro principales deudores de la cuenta general de recursos del FMI -Argentina, Ucrania, Pakistán y Egipto-, y de 0,94 para el principal deudor del FMI -Argentina. En particular, el modelo RF entrenado con información entre 2002 y 2021 emite sucesivas señales tempranas de alerta sobre el incumplimiento de un número significativo de metas externas por parte de Argentina en el período 2022-2024. La selección de variables del modelo sugiere que cuanto mayor es el retraso cambiario previo al programa, y menor es el ajuste del tipo de cambio al inicio del mismo, mayor es la probabilidad de incumplimiento de las metas externas futuras del programa.

Palabras clave: *International Monetary Fund* (IMF); *Quantitative Performance Criteria* (QPC); *Monitoring of Fund Arrangements* (MONA); *Machine Learning* (ML); *Random Forest* (RF).

Abstract. The study evaluates the out-of-sample performance of the *Random Forest* (RF) machine learning model in predicting non-compliance with the *External Quantitative Performance Criteria* (QPCs) or external targets of International Monetary Fund (IMF) loan programmes. The IMF's *Monitoring of Fund Arrangements* (MONA) database was used to train and test the model. The model was trained using data from 2003 to 2021, and its predictive ability was tested for the period 2022–2024. The model achieves an $F1_w$ score of 0.87 for the 38 debtor countries in the test set, 0.88 for the four largest debtors under the IMF's General Resources Account—Argentina, Ukraine, Pakistan and Egypt—and 0.94 for the IMF's largest debtor—Argentina. In particular, the RF model trained using data from 2002 to 2021 issues a series of early warning signals regarding Argentina's failure to meet a significant number of external targets during the 2022–2024 period. The model's variable selection suggests that the greater the exchange rate overvaluation prior to the programme and the smaller the exchange rate adjustment at the start of the programme, the higher the probability of non-compliance with the programme's external targets.

Key words: *International Monetary Fund* (IMF); *Quantitative Performance Criteria* (QPC); *Monitoring of Fund Arrangements* (MONA); *Machine Learning* (ML); *Random Forest* (RF).

The analysis presented is solely that of the author and does not necessarily reflect the opinions of third parties. Any errors it may contain are the sole responsibility of the author. For any queries, criticism or comments, please do not hesitate to contact me at augustocomisso@gmail.com.

Agradecimientos

En primer lugar, quiero expresar mi agradecimiento al director de la Maestría en Ciencias de Datos de la Universidad de San Andrés, el Dr. Fraiman, por haber confiado en mí para participar como alumno en ella. Extiendo mi agradecimiento a cada uno de los profesores de la maestría, que me han ayudado a desarrollar habilidades en inteligencia artificial, estadística y programación. En particular, le debo mucho a la Dra. Svarc, ya que gracias a su capacidad para combinar un alto nivel técnico y pedagógico he aprendido a utilizar las herramientas de *machine learning*.

Mis experiencias laborales han contribuido profundamente a este trabajo. Debo expresar mi agradecimiento a los Ministros de Economía de la provincia de Santa Fe, Ángel Sciara y Pablo Olivares, por su inestimable orientación para comprender la política fiscal. También debo mucho a mis colegas del Banco Central de la República Argentina (BCRA). Gracias a ellos he podido comprender con mayor profundidad la política monetaria y cambiaria. Por último, siguiendo el orden cronológico, quiero expresar mi agradecimiento al Banco Central de Malta (CBM), que me ha permitido profundizar en la comprensión del Fondo Monetario Internacional (FMI) y de la economía global.

Mi más profundo agradecimiento a Ivonne, por su constante apoyo y comprensión durante este proceso académico. Su paciencia y palabras de aliento han sido fundamentales para poder culminar esta investigación.

El análisis presentado es exclusivamente del autor y no refleja necesariamente las opiniones de terceros. Cualquier error que pueda contener es responsabilidad exclusiva del autor. Para cualquier consulta, crítica o comentario, por favor no dude en ponerse en contacto vía augustocomisso@gmail.com.

Índice general

Resumen	i
Agradecimientos	iii
Índice general	v
1 Introducción	1
2 Base de datos	4
2.1. Base de datos MONA	4
2.2. Base de datos de entrenamiento y testeo	5
2.3. Etiquetas	5
2.4. Características	6
2.5. Valores faltantes	11
2.6. Limpieza de datos	11
3 Metodología	12
3.1. Sets de entrenamiento, validación y prueba	12
3.2. Equilibrio de clase	14
3.3. Selección del modelo	14
3.4. Hiperparámetros	15
3.5. Métricas de evaluación	16
3.6. Selección del umbral	17
3.7. Importancia de las características	17
4 Análisis de resultados	19
4.1. Train-test split	19
4.2. Sobresampleo clase minoritaria	23
4.3. Hiperparámetros, umbral y re-entrenamiento	23
4.4. Performance fuera de la muestra	24
4.5. Robustez a variaciones del umbral	26
4.6. Análisis de la importancia de las características	27
4.7. Robustez a exclusión de variables	30
5 Conclusiones	31
	v

6	Anexo	33
	Bibliografía	42

CAPÍTULO 1

Introducción

Los programas de financiación externa respaldados por el Fondo Monetario Internacional (FMI) tienen un doble objetivo: i) proporcionar financiación a sus miembros para que puedan corregir los desequilibrios de sus balanzas de pagos sin recurrir a medidas perjudiciales para la economía nacional o internacional, y ii) que los países miembros hagan un uso temporal de sus recursos (IMF, 2020) [9]. El espíritu de este doble objetivo es garantizar que el país está aplicando políticas que abordarán, en lugar de simplemente retrasar, la resolución de sus problemas externos y que, en consecuencia, solo utilizará de forma temporal los recursos del FMI (IMF, 2023) [10].

El diseño de los programas de financiación del FMI incluyen metas que tienen por objeto contribuir al cumplimiento simultáneo de este doble objetivo. Tras diseñar y pre-aprobar un préstamo, el personal y el directorio ejecutivo del FMI llevan a cabo revisiones periódicas para evaluar el cumplimiento de las *quantitative performance criteria* (QPCs) o metas del programa. Para poder acceder a un nuevo tramo de financiación del programa, los ministros de economía de los países deudores deben demostrar al directorio ejecutivo del FMI que han cumplido las metas pertinentes a cada revisión. Alternativamente, si se constata que un país incumple una o varias metas, pero el directorio ejecutivo confía en que se cumplirán las metas en el futuro, este tiene la facultad de aprobar un *waiver* y desembolsar un nuevo tramo del crédito. En consecuencia, los directores ejecutivos del FMI deben decidir en cada revisión si se desembolsará un nuevo tramo del crédito para continuar con el ajuste ordenado del sector externo o si, por el contrario, se abandonará el programa, lo que probablemente acelerará y llevará a un ajuste desordenado del sector externo del país.

El cumplimiento de las metas de los programas correctamente diseñados se considera esencial para alcanzar simultáneamente el objetivo dual del FMI (ECB, 2019) [5]. En particular, las metas externas desempeñan un papel central al favorecer la realineación del tipo de cambio real y el ajuste externo, la acumulación de reservas internacionales y la utilización temporal de los recursos del FMI. El incumplimiento repetido de las metas externas puede dar lugar a procesos de apreciación cambiaria no sostenibles que implican la utilización reiterada de recursos del FMI y que solo retrasan y agravan el ajuste externo.

En la práctica, algunos países sufren problemas crónicos de balanza de pagos y dependen reiteradamente de los préstamos del FMI. Argentina, entre otros países, es un ejemplo de ello¹. Al finalizar el año 2019, el 85 % del uso de los recursos de la cuenta GRA del FMI se explicaba por en Argentina (48 %), Egipto (13 %), Ucrania (10 %), Pakistán (7 %) y Grecia (7 %) -Figura 1.1. En

¹ El directorio ejecutivo del FMI aprobó en junio de 2018 el programa 770 con Argentina, el que fuera el *stand-by* más grande en la historia del Fondo (IMF, 2021) [7]. En agosto de 2019, con sólo cuatro revisiones realizadas de las doce previstas, el acuerdo fue considerado *off track*. Posteriormente, al igual que el programa 770 (2018-2019), y tras el incumplimiento sucesivo de las metas externas, el programa 826 (2022-2024) también fue considerado *off-track*. En la actualidad, Argentina es el mayor deudor del FMI. Su deuda representa aproximadamente el 46 % del crédito de la cuenta general de recursos (GRA) del FMI.




Figura 1.1: Uso de los recursos de la cuenta general de recursos (GRA) del FMI, 26 de diciembre de 2019. Fuente: FMI (2019) [8].




Figura 1.2: Uso de los recursos de la cuenta general de recursos (GRA) del FMI, 19 de diciembre de 2025. Fuente: FMI (2025) [11].

contraste, al finalizar el año 2025, aproximadamente el 81 % del uso de los recursos de la cuenta GRA del FMI se concentraba Argentina (46 %), Ucrania (11 %), Pakistán (8 %), Ecuador (8 %) y Egipto (7 %) -Figura 1.2. En este marco, Argentina, Ucrania, Pakistán y Egipto se presentan como países que han utilizado los recursos del FMI de forma significativa y reiterada.

El presente trabajo tiene dos objetivos. El objetivo general es investigar la posibilidad de desarrollar una herramienta de aprendizaje automático que emita una alerta temprana de incumplimiento de las metas externas. Esta herramienta sería de utilidad en el momento en que el directorio ejecutivo del FMI debe decidir la liberación de nuevos tramos de financiación u obligar al rediseño del programa. El objetivo específico es determinar si este modelo, entrenado con datos entre 2003 y 2021, habría emitido alertas tempranas sobre el incumplimiento sucesivo de las metas externas por parte de Argentina, el principal deudor del FMI, durante el período 2022-2024.

Las técnicas de aprendizaje automático o *Machine Learning* (ML) tienen el potencial de proporcionar señales de alerta temprana sobre el incumplimiento de las metas externas por parte de los deudores del FMI. Una de las principales ventajas de estas técnicas es su capacidad para modelar relaciones no lineales. Sin embargo, a pesar de su potencial utilidad, no se han llevado a cabo estudios que hayan utilizado técnicas de aprendizaje automático con la base de datos *Monitoring of Fund Arrangements* (MONA) para predecir el incumplimiento de las metas externas

de los principales deudores del FMI. El presente trabajo tiene por objeto abordar esta brecha en la literatura.

La estrategia de investigación consta de varios pasos sucesivos. El primero de ellos fue la creación de una base de datos a partir de la base de datos MONA del FMI a disposición del directorio ejecutivo. Esto permitió disponer de las etiquetas que indican si se han cumplido o no las metas externas y de las características que podrían ayudar a clasificarlas. A continuación, se crearon los conjuntos de entrenamiento, validación y prueba del modelo siguiendo un enfoque temporal. Inicialmente el modelo fue entrenado sobre el set de entrenamiento (2003-2016) y los hiperparámetros del modelo RF se obtuvieron del set de validación (2017-2021), al igual que el umbral que se utilizará en la prueba fuera de la muestra. A continuación, se reentrena el modelo con estos hiperparámetros sobre un nuevo set de entrenamiento (2003-2021). Por último, se evaluó el rendimiento del modelo fuera de la muestra (2022-2024) y se consideró la robustez de sus resultados.

Los capítulos restantes están organizados de la siguiente manera: el capítulo 2 ofrece una descripción general de la base de datos y el capítulo 3 describe la metodología estadística empleada. El capítulo 4 presenta la evidencia empírica. Por último, el capítulo 5 presenta las conclusiones.

CAPÍTULO 2

Base de datos

2.1. Base de datos MONA

La base de datos final para el entrenamiento y la prueba del modelo se crea enteramente a partir de la base de datos *Monitoring of Fund Arrangements* del FMI (MONA). Esta última incluye información sobre aproximadamente 300 programas entre los años 2000 y 2025. Los datos utilizados para entrenar y probar los modelos proceden únicamente de MONA, no utilizándose fuentes de información adicionales. Debido a las falencias de la base de datos MONA, la creación de una base de datos final para entrenar y testear el modelo supuso superar diversos desafíos.

Interpretación. La base de datos MONA carece de documentación técnica formal, lo que dificulta su interpretación. Las limitadas definiciones disponibles en el sitio web del FMI no sustituye adecuadamente a los documentos formales ausentes. Por ejemplo, los usuarios se encuentran con frecuencia con columnas que contienen referencias y categorías no definidas formalmente. Ello obliga a los usuarios a recurrir a su propia experiencia y a fuentes alternativas de información para deducir su significado.

Estructuración. Adicionalmente, MONA no se ajusta a las mejores prácticas de la construcción de bases de datos normalizadas. Los usuarios de MONA deben gestionar ocho tablas Excel independientes¹. Estas tablas carecen de claves comunes para realizar consultas y contienen información duplicada. Esto obliga a los usuarios a crear sus propias claves para consolidar la información y realizar las consultas pertinentes. Además, se han incluido como columna observaciones que deberían ser introducidas como filas, lo que obliga al usuario a pivotar y reestructurar la información.

Limpieza. Los usuarios de MONA deben también llevar a cabo un minucioso proceso de limpieza de datos. La base de datos adolece de valores faltantes, errores en la introducción de datos y una estandarización inconsistente de los datos categóricos. A manera de ejemplo, en la columna *Units*, el sistema puede utilizar categorías como ‘US\$ (billions)’, ‘USD (millions)’ o ‘US\$’ para referirse a la misma unidad de cuenta.

Como resultado, los investigadores que utilizan MONA deben invertir una cantidad considerable de tiempo y esfuerzo en interpretar, estructurar y limpiar los datos. Ello ha sido observado oficialmente por la Oficina de Evaluación Independiente del FMI [12].

¹Estas tablas son: 1. *Description*; 2. *Program Goals and Reform Strategies*; 3. *Purchases*; 4. *Reviews*; 5. *QPC*; 6. *Other QPC and Indicative Targets*; 7. *Combined SPC PA SB*; 8. *Macroeconomic Indicators*. El presente trabajo utiliza datos de las tablas 1, 3, 4, 5 y 8.

2.2. Base de datos de entrenamiento y testeo

La base de datos final utilizada para el entrenamiento y la evaluación del modelo se creó a partir de la base de datos MONA utilizando una estrategia de cuatro pasos. En un primer paso, se tomó como ‘tabla maestra’ una de las ocho tablas, la tabla *Quantitative Performance Criteria (QPC)*. Esta tabla contiene la información necesaria para crear las etiquetas *-labels-* y un número de características *-features-* relacionadas a las mismas. En un segundo paso, se generaron claves comunes *-keys-* a partir de columnas existentes en las diversas tablas con el objeto de permitir la transferencia de características hacia la tabla maestra². En tercer lugar, tras consolidar toda la información en una única tabla maestra, se llevaron a cabo tareas de limpieza de datos. Por último, guiado por la intuición económica, se crearon nuevos *features* a partir de los *features* existentes. La base de datos final de entrenamiento y testeo y el código en R para crearla a partir de las tablas MONA se pueden encontrar en el repositorio [GitHub](#) de este trabajo.

2.3. Etiquetas

El objetivo del modelo es predecir y clasificar las metas externas³ como cumplidas (0) o no cumplidas (1). La tarea del director ejecutivo del FMI consiste en desembolsar un nuevo tramo del crédito si espera que se cumplirán las metas, o no desembolsarlo y forzar un rediseño del programa si espera que no se cumplirán.

El cumplimiento de las metas externas de un programa bien diseñado se considera necesario para garantizar el uso temporal de los recursos del FMI. Durante la fase de entrenamiento, con el fin de aumentar el número de observaciones, se incluyen metas externas y fiscales. Sin embargo, en la medición del rendimiento fuera de la muestra solo se incluyen las metas externas. La sección 4.7 presenta un análisis de sensibilidad de las conclusiones a la exclusión de las etiquetas fiscales durante la etapa de entrenamiento.

La columna *Status* de la tabla *QPC* de MONA proporciona información sobre el estado de cumplimiento de las metas. El estado de un QPC se clasifica en MONA como M (*Met* o Cumplido), NM (*Not Met* o No Cumplido), W, WA o WM (diferentes clases de *Waivers* o Exenciones), PC (*Pending Completion* o Pendiente de Completar) o Mod (*Modified* o Modificado). Antes de la fecha de su revisión, la meta se clasifica inicialmente como PC y, posteriormente, adopta alguna de las restantes categorías.

Las etiquetas que debe predecir el modelo se crean reduciendo estas categorías a dos: metas cumplidas (0) y no cumplidas (1). Luego de filtrar la base de datos para excluir las observaciones clasificadas como PC, la variable *Status* se transformó en una variable *dummy*. Las categorías incluidas en la etiqueta ‘No Cumplido’ (1) comprenden las metas no cumplidas (NM), las metas exentas (W, WA o WM) y las metas modificadas (Mod). Se ha comprobado que las conclusiones de este trabajo son robustas a la exclusión de las metas exentas y modificadas de la definición de ‘No Cumplido’.

²La clave, en su forma más detallada, consta del código del país, el año de aprobación del programa, el año en que se prevé que finalice el programa, el número de referencia del programa, el número de revisión y el número que identifica la clase QPC. Por ejemplo, la clave ‘213.2018.2021.770.R3.32’ se refiere al país 213 (Argentina), lo que indica que el programa comenzó en 2018 e inicialmente se esperaba que finalice en 2021. Se trata del programa número 770, la tercera revisión (R3), y se refiere a un QPC externo (32).

³Se excluyen las siguientes clases de QPCs: ‘*Total domestic credit*’ (1), ‘*Credit to Government/public sector*’ (16), ‘*Medium/Long Term External Debt*’ (47), ‘*Medium/Long term External Debt Subceiling*’ (74), ‘*Short term Debt*’ (84), ‘*No New arrears/default(continuous injunction)*’ (107), ‘*Ceiling on External Arrears*’ (114), y ‘*Domestic Arrears*’ (149); ‘*Fiscal Balance*’ (135).

2. Base de datos

2.4. Características

La base de datos final contiene 121 columnas: la etiqueta que indica si la meta fue cumplida (*Status*), la variable que distingue entre metas fiscales y metas externas (*QPC Criteria Order*), y 119 características o *features* -Cuadro 6.1. Un subgrupo de estas características se encontraban originalmente en la tabla maestra *QPC* y otro subgrupo fueron migradas desde otras tablas de MONA utilizando las claves creadas. Las restantes características fueron creadas a partir de estas características originales de las tablas de MONA.

Estas características se relacionan con el programa, la revisión o con aspectos específicos de la meta. Un programa del FMI suele implicar varias revisiones (R), cada una de las cuales suele incluir varias metas (QPCs). Por consiguiente, las características asociadas a una meta particular pueden formar parte de un programa -y ser comunes a todos las metas de dicho programa-, formar parte de una revisión específica -y ser comunes a todas las metas de dicha revisión- o ser específicas de la meta cuya etiqueta se intenta predecir -Cuadro 2.1. El diccionario de características se puede descargar del repositorio [GitHub](#) de este trabajo o consultarse en el anexo.

Tipo de característica	Cantidad de características
Comunes a todas las metas del programa	88
Comunes a todas las metas de la revisión	15
Específicas de la meta	16
Características totales	119

Cuadro 2.1: Características relacionadas con el programa, con la revisión o características específicas de la meta (QPC).

2.4.1 Características relacionadas con el programa

La base de datos incluye 88 características relacionadas con los programas. Estas se relacionan con la clase de programa, el monto total preaprobado, el momento coyuntural que existe el programa y el país que accede al programa. También se tienen en cuenta variables macroeconomicas que reflejan el escenario previo al programa, y el escenario base futuro esperado por el personal del FMI⁴ -Cuadro 2.2. La teoría y experiencia indican que estas características podrían ayudar a predecir el incumplimiento de una meta externa.

Clase de programa. En primer lugar, las metas externas de determinados programas podrían ser más propensas a incumplirse. Las principales categorías de programas son *Stand-By Arrangement* (SBA), el cual financia problemas de balanza de pagos a corto plazo, y el *Extended Fund Facility* (EFF), el cual se centra en los problemas de balanza de pagos a medio plazo. Ambos tipos de programas pertenecen a la cuenta GRA (*General Resource Account*) utilizada para financiar

⁴Las variables macroeconómicas se obtuvieron de la tabla *Macroeconomic Indicators*, que abarca un período comprendido entre tres años antes ($t - 3$) del inicio (t) del programa y cuatro años después ($t + 4$), basándose en las proyecciones del personal del FMI. Las variables incluidas son: BXG (*Exports of goods f.o.b.*); BMG (*Imports of goods c.i.f.*); BXS (*Exports of services*); BMS (*Imports of services*); NM (*Imports of goods and services*); NX (*Exports of goods and services*); BI (*Income, net*); BTR (*Current transfers, net*); BCA (*Balance on current account*); NGS (*Gross national savings*); BK (*Balance on capital account*); BF (*Balance on financial account*); BFD (*Direct investment, net*); BFRA (*Reserve assets, includes Reserve Position in the Fund*); D (*Total external debt, gross*); NGDP (*Gross domestic product*); NGDP_R (*Gross domestic product, constant prices*); NFI (*Gross fixed capital formation*); NCG (*Public final consumption expenditure*); NCP (*Private final consumption expenditure*); PCPI (*Consumer prices, period average*); PCPIE (*Consumer prices, end of period*); ENDA (*National currency units per USD, period average*); FMB (*Broad money*).

Tipo de variable	Cantidad de variables
Clase de programa	14
Monto del programa	2
Factores estructurales y shocks	2
Escenario previo	32
Escenario base (futuro)	36
Registro contable de las variables	2
Total	88

Cuadro 2.2: Características relacionadas con el programa.




Figura 2.1: Número de QPCs externos y fiscales cumplidos (0) y no cumplidos (1) entre 2003 y 2024 según clase de programa.

préstamos no-concesionales a países emergentes. Se tuvieron en cuenta diversos tipos de programas⁵ -Figura 2.1.

⁵Los programas SCF (*Stand-By Credit Facility*) y el ECF (*Extended Credit Facility*) también se centran en problemas de balanza de pagos a corto y medio plazo, al igual que el antiguo ESF (*Exogenous Shocks Facility*) y PRGF (*Poverty Reduction and Growth Facility*). Sin embargo, estos últimos programas pertenecen al trust PRGT (*Poverty Reduction and Growth Trust*), que se especializa en conceder préstamos en condiciones favorables -concesionales- a países de bajos ingresos. Otras categorías representan una combinación de las anteriores. También fueron incluidos instrumentos de señalización que no implican desembolso de recursos financieros: PCI (*Policy Coordination Instrument*) y PSI (*Policy Support Instrument*). En total, 14 variables dummy reflejan los diferentes tipos de programas.

2. Base de datos

Monto del programa. En segundo lugar, el monto total o *access* del programa, podría ayudar a pronosticar si se incumplirá una meta. La intuición previa sugiere que un acceso excepcionalmente alto podría estar correlacionado con mayores incumplimientos. La variable *Total Access* se refiere al monto total de crédito pre-aprobado que se prevé desembolsar en tramos futuros, ante cada revisión de las metas, medido en millones de derechos especiales de giro (DEG). Para tener en cuenta los efectos nominales, se ha creado una nueva variable *proxy* que expresa este importe nominal en relación con las exportaciones del país.

Factores estructurales y shocks. Algunos países pueden tener una mayor tendencia al incumplimiento de las metas debido a sus características estructurales específicas, por ejemplo, a causa de sus instituciones. Para abordar esta cuestión, se introduce la variable que indica el ID (número identificador) del país que accede a la financiación. Por otro lado, con el fin de capturar el contexto temporal y la existencia de shocks que podrían afectar el cumplimiento de la meta, se incluye el número o ID del programa, el cual aumenta a medida que transcurre el tiempo.

Escenario previo. Se consideran variables que dan un *proxy* del ‘diagnóstico’ o situación pre-programa. Los desequilibrios mayores preexistentes podrían contribuir a un menor cumplimiento de las metas pactadas.

Se considero el nivel de precios y el nivel de producto bruto interno durante el período comprendido entre tres años antes ($t - 3$) y el período previo al inicio ($t - 1$) del programa. Para evitar problemas de nominalidad, estas variables se expresaron en referencia al tipo de cambio nominal (ENDA) del mismo período. Por ejemplo, la variable $T_1_PCPI_real$ es el conciente entre el índice de precios de consumidor (PCPI) en el periodo $t - 1$ y el tipo de cambio nominal en el período $t - 1$. Por su parte, la variable $T_3_NGDP_usd$ es el cociente entre el producto bruto interno (NGDP) en el periodo $t - 3$ y el tipo de cambio nominal en el período $t - 3$.

Complementariamente, se crearon nuevas variables para captar la evolución de las principales variables macroeconómicas entre los momentos $t - 3$ y $t - 1$. Estas nuevas variables se expresaron en términos de variaciones porcentuales entre períodos. Por ejemplo, $var_t_t_3_BMS$ expresa la variación porcentual de las importaciones de servicios (BMS) entre el momento t y el momento $t - 3$. Ello permite dar información al modelo respecto del diagnóstico pre-programa del staff del FMI al momento de la evaluación de la meta.

Escenario base. Se introducen variables *proxys* del ‘escenario base’ futuro supuesto por el staff del FMI. Un escenario base futuro optimista podrían dar lugar a metas igualmente optimistas y difíciles de cumplir, y viceversa.

Se considero el nivel de precios y el nivel de producto bruto interno durante el período comprendido entre el año de inicio del programa (t) y el cuarto año ($t + 4$) del programa. Para evitar problemas de nominalidad, estas variables se expresaron en referencia al tipo de cambio nominal (ENDA) del mismo período. Por ejemplo, la variable T_PCPIE_real es el cociente entre el índice de precios de consumidor en el periodo t y el tipo de cambio nominal en el período t . Por su parte, la variable $TX4_NGDP_usd$ es el cociente entre el producto bruto interno en el periodo $t + 4$ y el tipo de cambio nominal en el periodo $t + 4$.

Complementariamente, se crearon nuevas variables para captar la evolución de las principales variables macroeconómicas entre los momentos t y $t + 4$. Estas nuevas variables se expresaron en términos de variaciones porcentuales entre períodos. Por ejemplo, $var_t4_t_BXS$ expresa la variación porcentual de las exportaciones de servicios (BXS) entre el momento t y el momento $t + 4$. Ello permite dar información al modelo respecto del escenario base del staff del FMI al momento de la evaluación de la meta. Se indica con variables dummy si los datos macroeconómicos se presentan en el año calendario (CY) o en el ejercicio fiscal (FY).




Figura 2.2: Número de QPCs externos y fiscales cumplidos (0) y no cumplidos (1) entre 2003 y 2024 según el número de revisión.

2.4.2 Características relacionadas con la revisión

La base de datos incluye 15 características relacionadas con la revisión a la que pertenece la meta. Estas características se relacionan con el número de revisión, el tiempo transcurrido desde el inicio del programa hasta la revisión y el desembolso asociado a ésta -Cuadro 2.3.

Tipo de variable	Cantidad de variables
Número de revisión	1
Tiempo transcurrido hasta la revisión	2
Monto a desembolsar en la revisión	12
Total	15

Cuadro 2.3: Características relacionadas con la revisión.

Número de revisión. El número de revisión (R) puede ayudar a predecir el incumplimiento de la meta. Cada programa se somete a múltiples revisiones a lo largo de su existencia y algunas de ellas podrían tener mayor propensión a incumplir la meta. Si el QPC que se evalúa se valoró durante la primera revisión, el valor de la variable R es 1. El valor de R puede oscilar entre 0 -para el programa inicial- y 13 -la revisión máxima posible- Figura 2.2.

Tiempo transcurrido hasta la revisión y el desembolso. Las metas más distantes en el tiempo podrían tener mayor propensión al incumplimiento. Consecuentemente, se creó la variable QPC_date_span para medir el número de días transcurridos entre la fecha de aprobación del

2. Base de datos

programa y la fecha en la que se evalúa el cumplimiento del QPC, y la variable *Purchase_date_span* para medir el número de días transcurridos entre la fecha de aprobación del programa y la fecha en la que se hace el desembolso asociado a la revisión.

Desembolso de la revisión. Por último, el importe originalmente planeado a desembolsar en cada revisión podría utilizarse para predecir el incumplimiento del QPC. La variable *Purchase Original Amount* muestra el valor inicial asignado a cada desembolso cuando se diseñó el programa por primera vez. Para tener en cuenta la nominalidad, esta variable se expresa en relación al tipo de cambio (ENDA) para los diferentes periodos $t - 3$ a $t + 4$. Se incluyen a su vez variables dummy las cuales indican si el desembolso realizado fue por el importe original previsto, si se revisó o si no se dispone de información al respecto.

2.4.3 Características específicas del QPC

Finalmente, la base de datos incluye 16 características relacionadas con la meta que busca predecir el modelo. Estas características se encuentran relacionadas con el valor original de la meta, su unidad de medida, y el sesgo de la distribución de probabilidades de la variable macroeconómica target de la meta -Cuadro 2.4.

Tipo de variable	Cantidad de variables
Monto del QPC	10
Unidad de medida del QPC	5
Sesgo de la distribución	1
Total	16

Cuadro 2.4: Características específicas del QPC.

Valor original de la meta. Asignar un valor excesivamente ambicioso a cada meta podría contribuir a su incumplimiento. La variable *QPC Original Amount* representa el valor nominal inicial asignado a la meta. Estos valores se expresan en términos del tipo de cambio nominal (ENDA) de los periodos $t - 3$ a $t + 4$. También se crearon variables que tienen en cuenta la unidad de medida de la meta, ya sea en dólares estadounidenses (USD), en moneda nacional (NC) o en la unidad de cuenta del FMI (SDR), teniendo en cuenta también su expresión en millones o billones de unidades.

Sesgo de la distribución de la variable macroeconómica target de la meta. En los reportes del FMI es práctica habitual no solo proporcionar una estimación puntual de la variable proyectada, sino también indicar el sesgo de la distribución de probabilidades de dicha variable, lo que permite dar una referencia sobre el riesgo de incumplimiento al alza o a la baja de dicha estimación puntual. Por lo tanto, se crea una variable proxy que indica si, desde la perspectiva del director ejecutivo del FMI, quien debe aprobar el programa y los desembolsos, el sesgo de la distribución de la variable macroeconómica es al alza (1) o a la baja (-1).

Para el entrenamiento, cuando el valor observado ex post de la variable fue superior a la meta original, se asignó el valor 1; en caso contrario, se asignó el valor -1. A modo de ejemplo, en diciembre de 2022 se evaluó la meta de acumulación de reservas internacionales del programa 826 de Argentina. El valor original de la meta era de 5,8 billones de dólares estadounidenses y el valor observado finalmente fue de 5,4 billones de dólares estadounidenses. En este caso, la variable 'sesgo' tomó el valor -1. Cabe señalar que, no obstante, la meta se consideró cumplida, ya que el cumplimiento de la meta no se calcula en función de la meta original, sino tomando

como referencia la meta revisada, a la que se le asignó un valor de 5 billones de USD, frente al valor finalmente observado de 5,4 billones de dólares estadounidenses.⁶

En la fase de implementación, esta variable permite construir dos escenarios alternativos. El usuario del modelo no puede observar el sesgo ex ante, por lo que puede evaluar ambas alternativas. Según el valor que el analista le asigne a la variable ‘sesgo’ (1 o -1), se obtendrá el resultado del modelo alternativo en cuanto a la probabilidad de incumplimiento de la meta externa que se busca predecir. Alternativamente, si se elimina la variable ‘sesgo’, se podrá construir un escenario base ‘sin sesgo’.

2.5. Valores faltantes

Se utilizó un método fácilmente replicable para la imputación de valores faltantes. Se conservaron los features con un porcentaje menor o igual a 10 % de datos faltantes, mientras que se eliminaron aquellas con una porcentaje de datos faltantes mayor al 10 %. Tras aplicar este filtro, los datos faltantes restantes se completaron con el valor medio de la columna correspondiente. Los valores atípicos se conservaron en el análisis.

2.6. Limpieza de datos

Diversas tareas de limpieza de datos fueron fundamentales para la construcción de una base de entrenamiento y testeo de utilidad. Por ejemplo, el valor de la meta en MONA se encuentra expresado en diferentes monedas -e.g. dólares estadounidenses, euros, francos ruandeses, etc.- y expresado en millones o miles de millones de unidades. Debido a la falta de normalización en relación con la variable *Units*, las entradas se reclasificaron inicialmente en las siguientes categorías: miles de millones de dólares estadounidenses (USD), miles de millones de moneda nacional (NC) y miles de millones de derechos especiales de giro (DEG). El valor original de la meta se unificó y expresó en billones de unidades.

⁶A modo de ejemplo para el caso de las metas fiscales, en diciembre de 2022 se evaluó la meta de balance primario del gobierno federal del programa 826 de Argentina. El valor original de la meta era de -1759 billones de pesos y el valor observado finalmente fue de -1955 billones de pesos. En este caso, la variable ‘sesgo’ tomó el valor -1. Cabe señalar que, no obstante, la meta se consideró cumplida dado que la meta revisada fue de -2016 billones de pesos.

CAPÍTULO 3

Metodología

3.1. Sets de entrenamiento, validación y prueba

Performance fuera de la muestra. El objetivo del modelo es minimizar el error de predicción de etiquetas que no han sido utilizadas para entrenarlo. Dicho error de predicción se puede desagregar en tres componentes: error irreducible, sesgo y varianza (Tibshirani et al., 2009) [18].

$$\text{Error de predicción esperado} = \text{Error Irreducible} + \text{Sesgo}^2 + \text{Varianza}.$$

Equilibrio overfitting-underfitting. En la práctica, existe una relación de compromiso entre el sesgo y la varianza. Un modelo más complejo suele tener un sesgo menor, pero una varianza mayor, mientras que un modelo más simple tiende a presentar un sesgo mayor y una varianza menor. En otras palabras, existe una relación de compromiso entre el ajuste excesivo y el ajuste insuficiente del modelo durante su entrenamiento.

El objetivo de minimizar el error de predicción fuera de la muestra de entrenamiento es encontrar un equilibrio entre el sobreajuste y el subajuste del modelo en la etapa de entrenamiento (Fortmann-Roe, 2012) [6]. Un modelo sobreajustado *-overfitted-* a menudo captura el ruido en los datos de entrenamiento en lugar de identificar las tendencias subyacentes, lo que da lugar a un rendimiento deficiente fuera de la muestra de entrenamiento. Por el contrario, un modelo subajustado *-underfitted-* puede no poseer la complejidad necesaria para representar con precisión las relaciones subyacentes.

Sets. La implementación de una estrategia de división de datos ayuda a encontrar el equilibrio entre sobreajuste y el subajuste. En un entorno rico en datos, la mejor práctica consiste en dividir los datos en tres conjuntos independientes: 1) un ‘set de entrenamiento’ para entrenar al modelo a aprender posibles relaciones subyacentes; 2) un ‘set de validación’ para seleccionar entre diferentes especificaciones -hiperparámetros- del modelo y umbrales de clasificación; y 3) un ‘set de testeo’ para evaluar el rendimiento del modelo en datos no vistos, también conocido como rendimiento fuera de la muestra (Tibshirani et al., 2009) [18].

Time-split. El siguiente paso consiste en determinar cómo se dividirán los datos entre entrenamiento, validación y prueba. El error de un modelo puede variar significativamente en función de las observaciones incluidas en cada set. Aunque métodos de selección aleatoria como *k-fold cross-validation* y el *bootstrapping* resuelven este problema, no tienen en cuenta la estructura temporal de las series de tiempo. La naturaleza temporal de las series macroeconómicas hace que la división aleatoria genere filtración de datos, lo que viola la condición fuera de la



Figura 3.1: División temporal de los conjuntos (*sets*) de entrenamiento (*train*) inicial, validación, entrenamiento final y prueba (*test*).

muestra del set de testeo (Burman et al., 1994) [3]. Por el contrario, la división temporal de los datos en conjuntos de entrenamiento y prueba refleja dicha estructura y evita este problema.

Train final y test. En este marco, el primer paso consiste en dividir temporalmente el total de las observaciones en un conjunto de entrenamiento (*train*) final y otro de prueba (*test*) -rectángulo inferior en la Figura 3.1. El programa 826 (2022-2024) de Argentina, i.e. el programa finalizado y más reciente del principal deudor del FMI, define el período que abarca el set de test. Dado el set total, un vez obtenido el set de test, se obtiene como residuo el set de entrenamiento final. Los programas que contienen observaciones en ambos sets son eliminados, evitando de este modo la filtración de datos -zona sombreada en gris en la parte inferior de la Figura 3.1. Evitar la filtración de datos entre el conjunto de entrenamiento final y el conjunto de prueba implica asumir la pérdida de estos datos.

Train inicial y validación: hiperparámetros-umbral. El segundo paso consiste en dividir el conjunto de entrenamiento final en dos: entrenamiento inicial y validación -rectángulo superior en la Figura 3.1. Sobre el primero se preentrena el modelo y sobre el segundo se obtienen: i) los hiperparámetros óptimos -es decir, los que maximizan el área bajo la curva ROC; y ii) el umbral óptimo -es decir, el que maximiza el valor $F1_W$ (sección 3.5). Posteriormente, estos hiperparámetros y el umbral se utilizan para evaluar el modelo sobre el set de test final.

Para realizar la partición entre set de entrenamiento inicial y set de validación, se determina arbitrariamente que, luego de ordenarlos temporalmente, el último 10 % de los programas del set de entrenamiento final pertenezcan al conjunto de validación. Los programas restantes se destinan al entrenamiento inicial, descartándose aquellos que se solapaban temporalmente con el conjunto de validación -zona gris en el rectángulo superior de la Figura 3.1. Por tanto, se evita la superposición temporal entre ambos conjuntos y la filtración de datos, aunque esto supone perder datos durante la fase inicial de entrenamiento. No obstante, cabe señalar que las observaciones de estos programas eliminados forman parte del conjunto de entrenamiento final del modelo.

La sección 4.5 presenta un análisis de sensibilidad de la métrica $F1_W$ a variaciones del umbral derivadas de particiones alternativas entre el set de entrenamiento inicial y el set de validación.

Test. El modelo se evalúa fuera de la muestra en diversos subconjuntos del set de *test*. El conjunto de prueba incluye todos los programas financiados durante el período. Dentro de este conjunto, se crea un subconjunto de prueba que contiene las observaciones de los cuatro principales deudores del FMI con programas durante el período de prueba. Por último, dentro de este conjunto, se crea otro que contiene las observaciones de Argentina, el principal deudor del FMI.

Finalmente, cabe señalar que, con el fin de disponer de más observaciones en la fase de entrenamiento, el modelo se entrena con programas pertenecientes a las cuentas GRA (*General Resources Account*) y PRGT (*Poverty Reduction and Growth Trust*) considerando metas externas y fiscales. En contraste, el modelo fue testeado considerando metas externas. Cabe señalar que ello no genera incompatibilidades, ya que el modelo ha visto el subconjunto de ‘metas externas’ en la fase de entrenamiento y, por lo tanto, debería poder predecir el mismo subconjunto -o clase de observaciones- en la fase de test. La sección 4.7 presenta un análisis de sensibilidad de la métrica $F1_W$ a la exclusion de las etiquetas fiscales durante la etapa de entrenamiento.

3.2. Equilibrio de clase

La mayoría de las etiquetas corresponden a QPCs que se han cumplido. Este desequilibrio de clases podría hacer que el modelo desarrolle un sesgo hacia la predicción de la clase mayoritaria, en detrimento de su capacidad de detectar los casos de incumplimiento de las metas -i.e. la clase minoritaria.

Para abordar el desequilibrio en el conjunto de entrenamiento, se utiliza la técnica de sobremuestreo sintético de minorías (SMOTE). Se crean dos observaciones sintéticas para cada uno de los QPC no cumplidos, teniendo en cuenta sus cinco vecinos más cercanos. El sobre-muestreo se aplica tanto al set de entrenamiento inicial como al set de entrenamiento final.

3.3. Selección del modelo

Modelos alternativos considerados

El algoritmo *Random Forest* (RF) es el modelo de aprendizaje automático preferido para este estudio. En pruebas preliminares, RF supera tanto a los modelos tradicionales como a los modelos alternativos de aprendizaje automático (ML) en el conjunto de validación. Al mismo tiempo, RF demuestra una mejor relación entre rendimiento y tiempo de procesamiento computacional.

Los modelos logísticos tradicionales suelen ofrecer un rendimiento fuera de la muestra inferior al de los modelos de aprendizaje automático cuando existen relaciones no lineales entre las variables independientes y dependientes (FMI, 2005) [13]. Luego de comprobar ello para el presente estudio, se consideraran modelos alternativos de aprendizaje automático. Se evalúan modelos de redes neuronales, y se descartan debido a su tendencia a sobreajustar los datos, dado lo relativamente bajo número de observaciones disponibles. También se evalúa AdaBoost, y se descarta debido a su menor rendimiento en términos de tiempo de procesamiento computacional. Finalmente, se evalúa y descarta el modelo XGBoost, ya que su rendimiento es similar, pero inferior al del modelo RF.

Random Forest

CART. Los árboles de clasificación y regresión (CART), propuestos por Breiman et al. en 1984 [1], fueron el primer paso hacia el algoritmo RF. El algoritmo CART crea árboles de decisión mediante la partición recursiva de la muestra en subconjuntos disjuntos, seleccionando la variable que mejor discrimina entre las observaciones en cada paso. Dicho algoritmo, en un segundo paso, ‘poda’ el árbol para reducir el sobreajuste y mejorar su capacidad de generalización fuera de la muestra de entrenamiento. En la práctica, aunque CART tiene un sesgo bajo, adolece de una alta varianza, lo que afecta negativamente a su rendimiento fuera de la muestra de entrenamiento (Tibshirani et al., 2009) [18].

BA. El algoritmo Bootstrap Aggregating (BA), propuesto originalmente por Efron (1979) [4] y Tibshirani y Efron (1993) [17], tiene como objetivo mejorar el rendimiento de CART reduciendo su varianza y conservando su sesgo. La idea principal consiste en hacer crecer muchos árboles sin podar y promediar sus resultados. Cada árbol se construye a partir de una muestra aleatoria con reemplazo del conjunto de datos original. En consecuencia, el algoritmo utiliza la ley de los grandes números para promediar el ruido y preservar la señal. La principal desventaja de BA es que la reducción de la varianza es baja, ya que los árboles son muy similares. Intuitivamente, si todos los árboles fueran iguales, sería como si solo hubiera un árbol. La ‘sabiduría de las multitudes’ asume que los votantes son independientes y diversos, pero los árboles del algoritmo BA no lo son (Tibshirani et al., 2009) [18].

RF. Breiman (2001) [2] propuso el algoritmo *Random Forest* (RF), o bosque aleatorio, como alternativa para resolver los problemas de CART y BA. Este algoritmo mantiene el concepto de promediar las predicciones de múltiples árboles generados mediante el muestreo con reemplazo del conjunto de datos original. Al igual que CART, se elige la variable que mejor discrimina en cada paso. Sin embargo, a la hora de encontrar la mejor variable disponible, no se permite elegir la mejor de todas. RF selecciona aleatoriamente un subconjunto de variables entre las que se debe identificar la que permite la partición óptima. Este enfoque garantiza que los árboles resultantes sean más diversos, es decir, que estén menos correlacionados entre sí (Tibshirani et al., 2009) [18].

RF es uno de los algoritmos de aprendizaje automático más utilizados (IMF, 2021) [13]. Es popular porque puede manejar relaciones no lineales entre variables, crear modelos con bajo sesgo y varianza, y generar predicciones precisas para datos no vistos. Además, RF es computacionalmente eficiente en comparación con otros algoritmos de aprendizaje automático.

3.4. Hiperparámetros

El modelo RF se entrena sucesivas veces sobre el conjunto de entrenamiento inicial con combinaciones de hiperparámetros alternativos, y la mejor combinación de hiperparámetros del modelo se elige sobre el conjunto de validación. Se retiene la combinación de hiperparámetros que maximiza el área debajo de la curva (AUC) sobre el set de validación. Los hiperparámetros óptimos, que se encuentran en la fase de entrenamiento inicial y validación, se utilizan posteriormente para el entrenamiento final.

Inicialmente se construyen las grillas de posibles valores de los hiperparámetros -Cuadro 3.1. Esta incluye la alternativa de entre 500 y 1000 árboles (*Trees*). Cada árbol puede tener un máximo de 3, 5 ó 10 nodos (*Max nodes*). Cada nodo final puede tener un mínimo de 1, 5 ó 10 observaciones (*Node Size*). En cada nodo, el modelo debe elegir la mejor variable de un subconjunto (*mtry*) que, aleatoriamente, contiene un porcentaje de variables equivalente al 10 % ($0,1 \times p$) o al 30 % ($0,3 \times p$) del total de variables (p). A su vez, dicho subconjunto podría contener una cantidad de variables equivalente a la raíz cuadrada del total de variables ($\sqrt{p}$) o, alternativamente, una variable (1).

Hiperparámetros				
Trees	500	1000		
Max nodes	3	5	10	
Node size	1	5	10	
Variables (mtry)	1	$\sqrt{p}$	$0,1 \times p$	$0,3 \times p$

Cuadro 3.1: Grilla de hiperparámetros. La letra p representa el número total de características (*features*) de la base de datos.

3.5. Métricas de evaluación

TP-TN-FP-FN. Cada predicción del modelo puede clasificarse en una de cuatro categorías. Si RF predice correctamente el incumplimiento de la meta, la predicción se clasifica como verdadera positiva (TP), y si lo hace incorrectamente, se clasifica como falso negativo (FN). Si el modelo predice correctamente el cumplimiento de la meta, la predicción se clasifica como verdadera negativa (TN), y si lo hace incorrectamente, se clasifica como falso positivo (FP). A partir de estas cuatro categorías, se pueden construir diversas métricas para evaluar el rendimiento del modelo.

Métricas tradicionales. Este trabajo presenta las métricas usuales para medir el rendimiento de los modelos de aprendizaje automático, como la tasa de accuracy (AR), la tasa de recall (RR), la tasa de precisión (PR) y el F_1 score (F_1).

$$AR = \frac{TP + TN}{TP + FP + TN + FN}$$

$$RR = \frac{TP}{TP + FN}$$

$$PR = \frac{TP}{TP + FP}$$

y

$$F_1 = \frac{2 \cdot TP}{2 \times TP + FP + FN}$$

F1 score ponderado (F_{1W}). Resulta particularmente relevante predecir el incumplimiento de las metas de los programas más importantes, que se definen como aquellos que han utilizado más recursos del FMI -mayor *Access*- durante más tiempo -aproximado por la cantidad de metas del programa. A igual tiempo de acceso a los recursos del FMI, es más importante la meta que pertenece al programa que insume mas recursos totales del FMI. A igual monto de uso de recursos del FMI, es más importante la meta que pertenece al programa que los ha utilizado durante más tiempo.

La métrica de evaluación principal será el F_1 score ponderado (F_{1W}) definida por la ecuación (3.1). El F_{1W} se obtiene ajustando la métrica F_1 al asignar diferentes ponderaciones (w_i) a las distintas metas. La ecuación (3.1) del F_{1W} pondera los N casos de verdaderos positivos (TP), los L casos falsos positivos (FP) y los T casos falsos negativos (FN) de la siguiente manera:

$$F_{1W} = \frac{2 \cdot \sum_{n=1}^N w_n \cdot TP_n}{2 \cdot \sum_{n=1}^N w_n \cdot TP_n + \sum_{l=1}^L w_l \cdot FP_l + \sum_{t=1}^T w_t \cdot FN_t} \quad (3.1)$$

$$w_i = \frac{Access_i(billonesUSD)}{\sum_{k=1}^K Access_k} \quad (3.2)$$

donde el peso de la meta i -ésima (w_i) esta dados por la ecuacion (3.2), donde $K = N + L + T + H$ siendo H los verdaderos negativos. Con el objeto de ilustrar como se obtienen los ponderadores de las metas, el Cuadro 3.2 presenta un ejemplo de juguete.

	Meta	$Access_i$	w_i
1	QPC_1.1	2	2/9
2	QPC_1.2	2	2/9
3	QPC_1.3	2	2/9
4	QPC_2.1	1	1/9
5	QPC_2.2	1	1/9
6	QPC_2.3	1	1/9
	$\sum_k^6 Access_k$	9	

Cuadro 3.2: Ejemplo ‘de juguete’ para ilustrar la obtención de las ponderaciones de cada meta. Dos programas con tres metas cada uno, donde *QPC_1.2* representa la segunda meta del primer programa, y donde el primer programa tiene un acceso total de 2 billones de USD y el segundo programa posee un acceso total de 1 billón de USD.

3.6. Selección del umbral

Necesidad del umbral. El modelo RF estima la probabilidad de incumplir la meta. Por tanto, es necesario establecer un umbral de corte para reexpresar el resultado del modelo como ‘no cumplido’ (1) o ‘cumplido’ (0). Si la probabilidad prevista por el modelo se encuentra por encima del umbral, el QPC se etiquetará como ‘no cumplido’ (1). Si es igual o se encuentra por debajo del umbral, se clasificará como ‘cumplido’ (0).

Impacto del umbral sobre la performance del modelo. El umbral elegido afecta al rendimiento del modelo. Si el umbral se establece cerca de cero, la mayoría de los casos se clasificarán como ‘no cumplidos’ (1), lo que dará lugar a una mayor tasa de *recall* (RR), pero a una menor tasa de *precision* (PR). Por otro lado, si el umbral se establece más cerca de uno, los casos rara vez se clasificarán como ‘no cumplidos’ (1), lo que dará lugar a una mayor tasa de *precisión* (PR), pero a una menor tasa de *recall* (RR). En ambos casos extremos, el valor de F_{1W} será bajo. Por tanto, existe un umbral óptimo que maximiza el valor de F_{1W} en el set de test.

Selección del umbral. El presente trabajo evalúa el rendimiento del modelo fuera de la muestra utilizando el umbral identificado como óptimo en el set de validación. Luego de la validación de los hiperparámetros, se encuentra el umbral óptimo para el modelo en el set de validación. Posteriormente, dicho umbral es utilizado para evaluar el rendimiento del modelo sobre el set de test. En la sección 4.5 se presenta la sensibilidad de la métrica F_{1W} a los diferentes umbrales sobre el set de test.

3.7. Importancia de las características

Se presentan métricas alternativas para medir la relevancia de las variables explicativas. El criterio no global de los *valores Shapley* se utiliza para evaluar la importancia de las características. Alternativamente, los criterios globales *Mean Decrease Accuracy* y *Mean Decrease Gini* respaldan las conclusiones derivadas del primer criterio. Debe señalarse que estas medidas alternativas no implican causalidad, sino que tiene por objeto evaluar la contribución de una *feature* específico a la predicción final.

Shapley values. Se calculan los valores de *Shapley* [16]. Estos se utilizan para cuantificar la contribución de cada característica a la predicción realizada para una observación específica

3. Metodología

en relación con la predicción media. El valor de *Shapley* de una característica representa su contribución marginal media, teniendo en cuenta todas las combinaciones posibles de características. Es importante destacar que el orden en que se introducen las características no influye en la medición de sus contribuciones marginales.

Mean Decrease Gini. Los criterios globales miden la importancia agregada, i.e. para el total de observaciones, de las variables. El criterio *Mean Decrease Gini* mide la contribución de cada variable a la homogeneidad de los nodos. Cuando un nodo se divide utilizando una determinada variable, la impureza de Gini de los dos nodos descendientes es menor que la del nodo padre. Al calcular la disminución media de Gini en todos los árboles del bosque, podemos evaluar la importancia de cada variable.

Mean Decrease Accuracy. Alternativamente, la importancia de una variable en el modelo aumenta con su *Mean Decrease Accuracy*. Esta métrica indica cuánto *accuracy* se pierde cuando se excluye una variable específica del modelo. Cuanto mayor sea la disminución de la precisión tras excluir una variable, más importante se considerará dicha variable a efectos de clasificación [2].

CAPÍTULO 4

Análisis de resultados

El capítulo 4 presenta los resultados empíricos. El R Markdown de la presente sección se puede descargar del repositorio [GitHub](#) de este trabajo.

4.1. Train-test split

El modelo se entrenó inicialmente con datos entre los años 2003 y 2016. Sus hiperparámetros se validaron con datos entre 2017 y 2021. Una vez obtenidos sus hiperparámetros y el umbral óptimo, el modelo fue re-entrenado con datos entre 2003 y 2021, y evaluado con datos entre los años 2022 y 2024 -Figura 4.1.



Figura 4.1: División temporal de los sets de entrenamiento (*train*) inicial, validación, entrenamiento final y test.

Base inicial. La base de datos, previo a la división en sets, contiene 3013 observaciones, 2471 casos negativos (i.e. metas cumplidas) y 542 casos positivos (i.e. metas incumplidas), pertenecientes a 283 programas de 98 países entre los años 2003 y 2024. Incluye QPCs externos y fiscales, así como programas financiados con la cuenta general de recursos del FMI (GRA) y con el fondo fiduciario PRGT. La Figura 4.2 presenta la evolución de ambas etiquetas del período bajo análisis.

Base final. Luego de la partición inicial entre set de test y set de entrenamiento final -rectángulo inferior en la Figura 4.1-, la base contiene 2559 observaciones, 2124 casos negativos (i.e. metas cumplidas) y 435 casos positivos (i.e. metas incumplidas). En este paso se perdieron 454 observaciones, 347 casos negativos y 107 casos positivos, correspondientes a 25 programas que abarcaban ambos sets -zona gris en el rectángulo inferior en la Figura 4.1. La Figura 4.3 presenta la evolución de ambas etiquetas del período bajo análisis.

4. Análisis de resultados




Figura 4.2: Número de QPCs externos y fiscales cumplidos (0) y no cumplidos (1) de los programas financiados con GRA y PGRT entre 2003 y 2024 previo a la partición entre train final y test.

En un paso posterior se eliminaron las metas fiscales del set de test. Consecuentemente, la base final contiene 2245 observaciones, 1871 casos negativos (i.e. metas cumplidas) y 374 casos positivos (i.e. metas incumplidas) -Cuadro 4.3-, pertenecientes a 258 programas de 97 países entre los años 2003 y 2024 -Cuadro 4.2. Luego de eliminar las metas fiscales del set de test, la base de datos tiene 120 columnas -es decir, la columna con etiquetas y 119 columnas de características- y 2245 filas -Cuadro 4.1.

Columnas y filas	
Columna de etiquetas	1
Columnas de características	119
Filas u observaciones	2245

Cuadro 4.1: Cantidad de filas y columnas en la base de datos final.

Sets de test. El set de test final (GRA-38) contiene 150 observaciones, 123 casos negativos (i.e. metas cumplidas) y 27 casos positivos (i.e. metas incumplidas), pertenecientes a 40 programas de 38 países entre los años 2022 y 2024. Cabe señalar que, a pesar de denominarse GRA-38, el conjunto incluye programas financiados con la cuenta GRA y con el fondo PRGT. Nótese además que se eliminaron las metas fiscales del set de test, reteniéndose las metas externas. El subconjunto de los 4 principales deudores (GRA-4) del set de test contiene 18 casos negativos y 10 casos positivos, pertenecientes a 4 programas de 4 países -Argentina, Ucrania, Egipto y Pakistán. El subconjunto del principal deudor (GRA-1) del set de test, Argentina, contiene 4 casos negativos y 8 casos positivos.




Figura 4.3: Número de QPCs externos y fiscales cumplidos (0) y no cumplidos (1) de los programas financiados con GRA y PGRT entre 2003 y 2024 posterior a la partición entre set de entrenamiento final y de test. Contiene 253 metas fiscales cumplidas y 61 metas fiscales incumplidas para los años 2022-2024. El gráfico incluye 314 metas fiscales en el set de test que serán eliminadas en el set de test final.

Set de entrenamiento final. Dada la base de datos final y definido el set de test, el set de entrenamiento final se obtiene residualmente. Este contiene 2095 observaciones, 1748 casos negativos (83,4 %) y 347 casos positivos (16,6 %), pertenecientes a 218 programas entre los años 2003 y 2021.

Set de validación. Luego de la partición arbitraria del set de entrenamiento final entre set de validación y set de entrenamiento inicial -rectángulo superior en la Figura 4.1-, el set de validación contiene 250 observaciones, 208 casos negativos (83,2 %) y 42 casos positivos (16,8 %), pertenecientes a 23 programas entre los años 2017 y 2021.

Set de entrenamiento inicial. Dado el set de entrenamiento final, y obtenido el set de validación, se obtiene como residuo el set de entrenamiento inicial, el cual contiene 1524 observaciones, 1288 casos negativos (84,5 %) y 236 casos positivos (15,5 %), pertenecientes a 172 programas entre los años 2003 y 2016. Se perdieron temporalmente 321 observaciones correspondientes a 23 programas que pertenecían simultáneamente a los sets de entrenamiento inicial y de validación.

4. Análisis de resultados

Set	Programas	Fecha min.	Fecha max.
0.Base inicial	283	2003	2024
1.Train inicial	172	2003	2016
2.Validación	23	2017	2021
3.Train final	218	2003	2021
4. Test GRA-38*	40	2022	2024
5. Test GRA-4	4	2022	2024
6. Test GRA-1	1	2022	2024
7. Base final	258	2003	2024

Cuadro 4.2: Cantidad de programas y espacio temporal por set. La segunda columna indica el número de programas que contiene cada set. La tercera columna indica el año inicial del set y la cuarta, el año final. *Incluye programas financiados con la cuenta GRA y el fondo PRGT; y excluye metas fiscales.

Sets	Etiqueta 0	Etiqueta 1	Total etiquetas
0. Base inicial	2471	542	3013
% de 0	82,0 %	18,0 %	100,0 %
1. Train inicial	1288	236	1524
% de 1	84,5 %	15,5 %	100,0 %
2. Validación	208	42	250
% de 2	83,2 %	16,8 %	100,0 %
3. Train final	1748	347	2095
% de 3	83,4 %	16,6 %	100,0 %
4. Test GRA-38*	123	27	150
% de 4	82,0 %	18,0 %	100,0 %
5. Test GRA-4**	18	10	28
% de 5	64,3 %	35,7 %	100,0 %
6. Test GRA-1**	4	8	12
% de 6	33,3 %	66,7 %	100,0 %
7. Base final (3+4)	1871	374	2245
% de 7	83,3 %	16,7 %	100,0 %

Cuadro 4.3: Cantidad de observaciones con etiquetas de cumplimiento (0) y no cumplimiento (1) entre sets alternativos. En gris se señala el porcentaje que representan cada clase de etiqueta sobre el total de etiquetas de cada set. *Incluye programas financiados con la cuenta GRA y el fondo PRGT; y excluye metas fiscales. **Incluye programas financiados con la cuenta GRA; y excluye metas fiscales.

4.2. Sobresampleo clase minoritaria

El desequilibrio de clase original provoca que el modelo desarrolle un sesgo en la predicción a favor de la clase mayoritaria, lo que llevó a utilizar SMOTE. De las 2095 observaciones del set de entrenamiento final solo 347 casos son positivos (16,6 %). El desequilibrio es mayor entre las etiquetas de metas externas, ya que los casos positivos (i.e. metas incumplidas) solo representan el 11,5 % del total de etiquetas externas. En contraste con el set de entrenamiento, los casos positivos en el set de test GRA-4 representan el 35,7 %, y en el set de test GRA-1 representan el 66,7 %.

Set de entrenamiento inicial. El set de entrenamiento inicial originalmente incluye 1288 casos negativos (84,5 %) y 236 casos positivos (15,5 %). Luego de aplicar SMOTE, el set de entrenamiento inicial mantiene los 1288 casos negativos (64,5 %) y aumenta a 708 los casos positivos (35,5 %) -Cuadro 4.4.

Sets	Etiqueta 0	Etiqueta 1	Total etiquetas
Train inicial	1288	236	1524
	84,5 %	15,5 %	100,0 %
Train inicial con SMOTE	1288	708	1996
	64,5 %	35,5 %	100,0 %

Cuadro 4.4: Desbalance de etiquetas en set de entrenamiento inicial sin y con SMOTE. En gris se señala el porcentaje de cada clase de etiqueta sobre el total de etiquetas.

Set de entrenamiento final. Por su parte, el set de entrenamiento final originalmente incluye 1748 casos negativos (83,4 %) y 347 casos positivos (16,6 %). Luego de aplicar SMOTE, el set de entrenamiento final mantiene los 1748 casos negativos (62,7 %) y aumenta a 1041 los casos positivos (37,3 %) -Cuadro 4.5.

Sets	Etiqueta 0	Etiqueta 1	Total etiquetas
Train final	1748	347	2095
	83,4 %	16,6 %	100,0 %
Train final con SMOTE	1748	1041	2789
	62,7 %	37,3 %	100,0 %

Cuadro 4.5: Desbalance de etiquetas en set de entrenamiento final sin y con SMOTE. En gris se señala el porcentaje de cada clase de etiqueta sobre el total de etiquetas.

4.3. Hiperparámetros, umbral y re-entrenamiento

Hiperparámetros. El entrenamiento sobre el set de ‘train inicial’ y su testeo sobre el set de validación permitió obtener los hiperparámetros que se presentan en el Cuadro 4.6. El número óptimo de árboles fue de 500 (Trees = 500). Se establece un límite al máximo de 3 nodos terminales para cada árbol (Max nodes = 3), lo cual evita que haya árboles muy profundos, disminuyendo el riesgo de *overfitting*. La cantidad mínima de observaciones en los nodos terminales se asigna en 1 (Node size = 1). Ante cada partición del árbol, el modelo debe seleccionar la variable óptima entre 36 variables elegidas al azar (mtry = 36), el cual representa el 30 % de las variables totales disponibles. La Figura 4.4 presenta la curva ROC del modelo RF sobre el set de entrenamiento inicial. El area bajo la curva ROC fue de 0,835 y el modelo no se observa sobreajustado.




Figura 4.4: Curva ROC del modelo RF sobre el set de entrenamiento inicial.

Hiperparámetros	
Trees	500
Max nodes	3
Node size	1
Variables (mtry)	36

Cuadro 4.6: Hiperparámetros validados del modelo RF. AUC: 0,835.

Umbral óptimo: $t = 0,25$.

Umbral. Obtenidos los hiperparámetros, se obtuvo un umbral óptimo para el modelo RF en el conjunto de validación de $t = 0,25$. Como resultado, si la probabilidad prevista por el modelo en el set de testeo supera el umbral 0,25, la etiqueta asignada al QPC es ‘no cumplido’ (1). Por el contrario, si la probabilidad predicha por el modelo es igual o está por debajo de dicho umbral, la etiqueta asignada es ‘cumplido’ (0). El bajo nivel del umbral óptimo sugiere la dificultad del modelo para asignar valores altos de probabilidad a las metas incumplidas.

Entrenamiento final. El modelo se re-entrenó sobre el set de ‘entrenamiento final’ utilizando los hiperparámetros obtenidos sobre el set de validación. La Figura 4.5 muestra la curva ROC del modelo RF sobre el set de entrenamiento final en comparación con la curva ROC del modelo RF sobre el set de entrenamiento inicial. El área bajo la curva ROC del entrenamiento final fue de 0,798 y el modelo no se observa sobreajustado.

4.4. Performance fuera de la muestra

Una vez re-entrenado, el modelo se sometió a pruebas fuera de la muestra utilizando el umbral obtenido sobre el set de validación. Se evaluó la performance del modelo sobre el set de test (GRA-38) y sobre dos subgrupos del mismo: GRA-4 y GRA-1.

Test GRA-38. Utilizando un umbral óptimo según el set de validación ($t = 0,25$), el rendimiento del modelo se resume en un valor F_{1w} de 0,87 para el conjunto de los 38 países en el set de




Figura 4.5: Curvas ROC del modelo RF sobre los sets de entrenamiento inicial y final.

testeo. El modelo predice correctamente 19 de las 27 metas externas incumplidas, 8 de las cuales corresponden a Argentina -Cuadro 4.8. En contraste, el modelo presenta un valor F_1 de 0,58, resultado de un buen recall ($RR=0,70$) pero una baja precisión ($PR=0,50$) -Cuadro 4.9. El contraste entre un valor F_{1w} de 0,87 y un F_1 de 0,58 pone en relieve la capacidad del modelo para detectar el incumplimiento los principales deudores del FMI versus los deudores de menor importancia relativa.

La Figura 4.6 muestra la curva ROC del modelo RF sobre el set de test en comparación con las curvas ROC del modelo RF sobre los sets de entrenamiento inicial y final. El área bajo la curva ROC del set de test fue de 0,861 -Cuadro 4.7.

Set	AUC
Train inicial	0,835
Train final	0,798
Test	0,861

Cuadro 4.7: Area debajo de la curva ROC (AUC) del modelo RF para los sets de entrenamiento inicial, final y set de test.

Test GRA-4. El rendimiento del modelo se resume en un valor F_{1w} de 0,88 para el caso de los 4 deudores que explican aproximadamente 72% de la deuda en la cuenta GRA: Argentina, Ucrania, Egipto y Pakistan. RF predice correctamente 9 de las 10 metas externas incumplidas. Puntualmente, el modelo clasifica correctamente 8 metas incumplidas de Argentina y la meta incumplida de Egipto. El coste de dicho rendimiento ha sido clasificar incorrectamente 7 de las 18 metas externas cumplidas por parte de GRA-4. El modelo obtiene un recall (RR) de 0,90 pero una precisión (PR) de 0,56, ambos resumidos en un F_1 de 0,69 -Cuadro 4.9.

Test GRA-1. El rendimiento del modelo se resume en un valor F_{1w} de 0,94 para el caso de Argentina (GRA-1). RF predice correctamente la totalidad de las metas externas incumplidas del programa 826 del FMI con Argentina. El coste de dicho rendimiento ha sido clasificar incorrectamente el 25 por ciento ($1/4$) de las metas externas cumplidas -Cuadro 4.8. El modelo obtiene un recall (RR) de 1,00 y una precisión (PR) de 0,89, ambos resumidos en un F_1 de 0,94

4. Análisis de resultados




Figura 4.6: Curvas ROC del modelo RF sobre los sets de entrenamiento inicial, final y test.

Real	Predicho	
	Cumplido	No cumplido
	Cumplido	No cumplido
Cumplido	104 / 11 / 3	19 / 7 / 1
No cumplido	8 / 1 / 0	19 / 9 / 8

Cuadro 4.8: Matriz de confusión del modelo RF sobre el set de test GRA-38 / GRA-4 / GRA-1 bajo umbral $t = 0,25$.

Set	AR	PR	RR	F_1	F_{1w}
GRA-38*	0,82	0,50	0,70	0,58	0,87
GRA-4	0,71	0,56	0,90	0,69	0,88
GRA-1	0,92	0,89	1,00	0,94	0,94

Cuadro 4.9: Principales métricas de rendimiento fuera de la muestra del modelo RF para diferentes subgrupos del set de test bajo umbral $t = 0,25$. *Incluye programas financiados con la cuenta GRA y el fondo PRGT.

-Cuadro 4.9. Para todos los umbrales iguales o menores a $t = 0,36$, el valor F_{1w} para Argentina es superior al valor F_{1w} de GRA-38 -Figura 4.7.

4.5. Robustez a variaciones del umbral

El modelo alcanza un valor F_{1w} igual o superior a 0,64 para los umbrales entre 0 y 0,36. En el set de test GRA-38, el modelo alcanza valores de F_{1w} entre 0,77 y 0,93 para valores de umbrales (t) entre 0,15 y 0,36 -Figura 4.7. El umbral que maximiza los resultados en los sets de test GRA-4 y GRA-38 se encuentra en el rango $[0,28 ; 0,36]$, valores superiores al umbral $t = 0,25$ obtenido en el set de validación -Figuras 6.4 y 6.5. Transitando de un umbral $t = 0,25$ a un umbral $t = 0,28$

en GRA-38, el $F1_w$ se eleva de 0,87 a 0,93 y el $F1$ de 0,58 a 0,70 -Cuadro 4.11. Ello se debe a la reducción de los casos falsos positivos, lo que aumenta la precisión del modelo de 0,50 a 0,70. Para el caso del set de test GRA-1, el umbral que maximiza los resultados se encuentra en el rango [0,15 ; 0,36], el cual incluye al umbral $t = 0,25$ obtenido en el set de validación -Figura 6.3.




Figura 4.7: Valores de $F1_w$ para umbrales alternativos para GRA-1 (ARG) y GRA-38 (GRA).

Real	Predicho	
	Cumplido	No cumplido
	Cumplido	No cumplido
Cumplido	115 / 11 / 3	8 / 7 / 1
No cumplido	8 / 1 / 0	19 / 9 / 8

Cuadro 4.10: Matriz de confusión del modelo RF sobre el set de test GRA-38 / GRA-4 / GRA-1 bajo umbral óptimo.

Set	AR	PR	RR	F1	$F1_w$	t
GRA-38*	0,89	0,70	0,70	0,70	0,93	[0,28 ; 0,36]
GRA-4	0,93	0,90	0,90	0,90	0,94	[0,28 ; 0,36]
GRA-1	0,92	0,89	1,00	0,94	0,94	[0,15 ; 0,36]

Cuadro 4.11: Principales métricas de rendimiento fuera de la muestra del modelo RF para diferentes subgrupos del set de test bajo umbrales óptimos (t). *Incluye programas financiados con la cuenta GRA y el fondo PRGT.

4.6. Análisis de la importancia de las características

El análisis de la importancia de las características permite observar la existencia de un subconjunto de variables de mayor relevancia relativa para la estimación de probabilidades de incumplimiento. Los diversos criterios utilizados -Figuras 4.8, 6.1, 6.2 y 4.9- coinciden en indicar un

4. Análisis de resultados

subconjunto de variables para la totalidad de países considerados. Estas variables son coherentes con la intuición económica. Para definir la probabilidad de incumplimiento de una meta externa, el modelo tiene en cuenta:

Sesgo de la distribución de la variable macroeconómica target de la meta. Un sesgo a la baja en la distribución de probabilidades de la variable macroeconómica objetivo aumenta la probabilidad de incumplimiento de la meta. Si el analista considera que la distribución de probabilidades del stock de reservas internacionales está sesgada a la baja (al alza), el modelo asignará una mayor (menor) probabilidad de incumplimiento de la meta externa. Esta variable permite plantear dos escenarios alternativos (según se asigne a la variable sesgo el valor -1 o 1) y asignar probabilidades de incumplimiento a cada uno de ellos. La exclusión de esta variable permite construir un escenario base ‘sin sesgo’.

Desembolsos generosos y ajuste cambiario insuficiente. Desembolsos (*Purchase*) generosos en relación con el tipo de cambio (ENDA) observado en los tres años previos del programa y proyectado para el primero año del programa aumenta la probabilidad de incumplimiento de la meta externa. Una posible interpretación sugiere que el país podría haber entrado en el programa con una fuerte sobrevaloración cambiaria y que el diseño del programa contempla un ajuste del tipo de cambio poco ambicioso -i.e. una financiación de los desequilibrios (*Purchase*) demasiada generosa- en relación a la meta de reservas internacionales establecida. El modelo detectaría estos desfases y los utiliza para indicar una mayor probabilidad de incumplimiento de la meta externa.

Meta externa original incompatible con el ajuste cambiario. Una meta externa original desalineada (*QPC Original Amount*) en relación con el tipo de cambio (ENDA) -observado en los tres años previos del programa y proyectado para los dos primeros años del programa- aumenta la probabilidad de incumplimiento. La lógica económica indica que el programa es muy optimista respecto del ajuste cambiario necesario que es compatible con la acumulación de reservas internacionales planeada. El modelo detectaría estos desalineamientos y los utilizaría para predecir el incumplimiento de la meta externa.

Meta externa original incompatible con el nivel de importaciones en el escenario base. Un escenario base optimista en términos de BMS (*Imports of services*) y BMG (*Imports of goods c.i.f*) aumenta la probabilidad de incumplimiento de la meta externa. La lógica económica indica que el programa es muy optimista respecto al nivel de crecimiento económico -e importaciones asociadas- que es compatible con la acumulación de reservas internacionales planeada. El modelo detectaría estos desalineamientos y los utilizaría para predecir el incumplimiento de la meta externa.

El caso de Argentina. El análisis de la importancia de las características para el caso particular de Argentina pone de relevancia las mismas variables que para el conjunto de países -Figuras 6.6 a 6.17. La intuición económica indica que, cuanto mayor es el proceso de atraso cambiario previo al programa, y cuanto menos ambicioso es el ajuste del tipo de cambio requerido al inicio del mismo, mayor es la probabilidad de que Argentina incumpla las metas externas del programa. En otras palabras, cuanto más generosos sean los desembolsos previstos desde el inicio del programa y menor el ajuste cambiario exigido por el programa desde el principio, mayor será la probabilidad de que Argentina incumpla las metas externas en el futuro. Este contexto de atraso cambiario pre-programa y ajuste cambiario inicial poco ambicioso es coherente con un sesgo pesimista en cuanto a la probabilidad de cumplimiento de las metas externas del programa.

4.6. Análisis de la importancia de las características




Figura 4.8: Importancia de las características según sus Shapley Values absolutos medios.




Figura 4.9: Shapley Values de las principales características.

4.7. Robustez a exclusión de variables

Al excluir las variables fiscales del set de entrenamiento y/o el sesgo entre las características, medido por la métrica F_1 sobre GRA-38, el modelo pierde su utilidad para predecir el incumplimiento de las metas externas por parte de los deudores de menor importancia relativa. Sin embargo, si se mide su rendimiento mediante la métrica F_{1w} , el modelo resulta relevante para predecir el incumplimiento de las metas externas por parte de los principales deudores del FMI - Cuadro 4.12. Los R Markdown de la presente sección se pueden descargar del repositorio [GitHub](#) de este trabajo.

Set y F_{1w}	I	II	III	IV
GRA-38*	0,87 (0,93)	0,67 (0,81)	0,66 (0,70)	0,76 (0,76)
GRA-4	0,88 (0,94)	0,69 (0,83)	0,69 (0,72)	0,69 (0,79)
GRA-1	0,94 (0,94)	0,80 (0,94)	0,80 (0,84)	0,80 (0,94)

Cuadro 4.12: Métrica F_{1w} obtenida fuera de la muestra para los casos: I) El modelo RF se entrenó con variables fiscales y externas y se incluyó la variable sesgo entre los *features*; II) como en el caso I, pero sin incluir variables fiscales; III) como en el caso I, pero sin incluir la variable sesgo; IV) como en el caso I, pero sin incluir variables fiscales y la variable sesgo. Los valores entre paréntesis indican el valor F_{1w} cuando se considera el umbral óptimo. *Incluye programas financiados con la cuenta GRA y el fondo PRGT.

La exclusión de las etiquetas fiscales durante el entrenamiento reduce el rendimiento F_{1w} del modelo en el set GRA-38, pero no influye en el set GRA-1. Teniendo en cuenta el umbral óptimo, el valor de F_{1w} disminuye de 0,93 a 0,81 sobre el set GRA-38 al comparar los escenarios I y II. Sin embargo, en el caso del GRA-1, el valor de F_{1w} se mantiene en 0,94 entre los escenarios I y II.

La exclusión de la variable sesgo entre las características reduce el rendimiento F_{1w} del modelo. Al pasar del escenario I al III, los valores de F_{1w} que logra el modelo se reducen de 0,93 a 0,70 en el set de datos GRA-38 y de 0,94 a 0,84 en el set de datos GRA-1.

La exclusión de la variable ‘sesgo’ permite trabajar con un escenario base ‘sin sesgo’ para los principales deudores del FMI. Alternativamente, la inclusión de la variable sesgo permite plantear escenarios futuros alternativos. En el momento de la predicción, el analista desconoce si la variable sesgo toma el valor -1 (sesgo a la baja) o 1 (sesgo al alza). El uso del modelo con ambos valores permite obtener la probabilidad de incumplimiento en cada escenario alternativo. De esta forma, sería posible crear el escenario base ‘sin sesgo’ y dos alternativos, junto con sus probabilidades de incumplimiento asociadas. A continuación, el juicio del experto debería determinar las probabilidades de ocurrencia asignadas a cada escenario.

CAPÍTULO 5

Conclusiones

Los programas de financiación externa respaldados por el FMI tienen un doble objetivo: i) proporcionar financiación a sus miembros para que puedan corregir los desequilibrios de sus balanzas de pagos sin recurrir a medidas perjudiciales para la economía nacional o internacional, y ii) que los países miembros hagan un uso temporal de los recursos del FMI. En contraste con dicho doble objetivo, hacia finales del año 2025, Argentina, Ucrania, Pakistán y Egipto se presentan como países que han utilizado los recursos del FMI de forma cuantiosa y reiterada.

El cumplimiento de las metas externas es instrumental para el cumplimiento del doble objetivo del FMI. El cumplimiento de metas externas bien diseñadas obliga al país a solucionar sus desequilibrios externos, lo que le permite acumular reservas internacionales suficientes para evitar el uso repetido de los recursos del FMI.

El directorio del FMI es el encargado de decidir un nuevo desembolso. Si el director ejecutivo del FMI espera que el país cumpla sus metas externas futuras -y considera que estas están correctamente diseñadas-, entonces votará a favor de un nuevo desembolso. Si, por el contrario, espera que el país no cumpla las metas externas -o considera que estas son poco ambiciosas-, podrá votar en contra del desembolso, lo que obligará al país a realizar un ajuste externo y a rediseñar el programa.

En dicho marco, el presente trabajo tuvo dos objetivos. El objetivo general fue investigar la posibilidad de desarrollar una herramienta de aprendizaje automático que emita una alerta temprana de incumplimiento de las metas externas. El objetivo específico fue determinar si este modelo, entrenado con datos entre 2003 y 2021, habría emitido alertas tempranas durante el período 2022-2024 sobre el incumplimiento sucesivo de las metas externas por parte de Argentina, el principal deudor del FMI.

Objetivo general. El resultado general es *mixto*. El modelo tiene un rendimiento relativo bajo a la hora de predecir el incumplimiento de las metas externas por parte de los *países de menor importancia relativa* en términos de monto de los recursos del fondo utilizados. El modelo presenta un buen nivel de recall, pero una *baja precisión*, lo que lo convierte en un modelo con un sesgo pesimista para la predicción del cumplimiento de las metas de los deudores de menor importancia relativa.

Al excluir las variables fiscales del set de entrenamiento y/o el sesgo entre las características, *el modelo deja de ser útil* para predecir el incumplimiento de las metas externas por parte de los deudores de menor importancia relativa. La variable sesgo contribuye significativamente a la asignación de baja probabilidad de incumplimiento de las metas efectivamente cumplidas, lo que reduce el coste en términos de precisión en que incurre el modelo al aumentar su capacidad de recall.

5. Conclusiones

No obstante, el modelo ha demostrado un *mejor rendimiento* en la predicción del incumplimiento de las metas externas por parte de sus *principales deudores*. En particular, ha demostrado su eficacia en la predicción del incumplimiento de las metas externas de *Argentina, Ucrania y Egipto*, que en diciembre de 2025 representaban el 64 % de la cartera de crédito GRA.

Objetivo específico. El modelo RF entrenado con información entre 2002 y 2021 *emite sucesivas señales tempranas* de alerta sobre el incumplimiento de un número significativo de metas externas por parte de Argentina en el período 2022-2024, lo que habría indicado la posible prórroga de sus problemas externos y la repetida utilización de los recursos del FMI.

Conclusión. El modelo se presenta como una herramienta que *podría haber sido útil* en el pasado y que *podría servir* de apoyo al directorio ejecutivo del FMI a la hora de tomar decisiones sobre nuevos desembolsos a favor de los *principales deudores* del FMI. En particular, el modelo resulta útil para generar alertas tempranas sobre el incumplimiento de las metas externas en los programas de Argentina, el principal deudor del FMI.

Contribución adicional del modelo (I): mejora del juicio de experto. El modelo contribuye, a su vez, a generar *intuición* sobre las variables que deberían considerarse a la hora de anticipar el incumplimiento de las metas externas futuras por parte de un país que solicita el desembolso de un nuevo tramo del crédito pre-aprobado con un alto nivel de acceso. Las probabilidades de incumplimiento futuro son mayores si el director ejecutivo considera que: 1) el país entra al programa con atraso cambiario y los desembolsos son generosos -i.e. el ajuste cambiario exigido es poco ambicioso-; 2) las metas externas son incompatibles con el ajuste cambiario exigido; 3) las metas externas son incompatibles con el crecimiento económico y las importaciones de bienes y servicios del escenario base.

Contribución adicional del modelo (II): construcción de escenarios alternativos y base ‘sin sesgo’. La introducción de la variable sesgo permite utilizar el modelo para construir escenarios alternativos (optimista y pesimista) y obtener las probabilidades de incumplimiento de las metas externas asociadas a cada uno de ellos. La exclusión de la variable sesgo permite construir un escenario base ‘sin sesgo’.

Contribución adicional del modelo (III): diseño del programa. Esta intuición no solo es relevante para predecir el incumplimiento de las metas externas de un programa ya diseñado, sino también para su diseño inicial. El modelo nos indica que el diseño del programa podría ser poco ambicioso en el ajuste cambiario y muy generoso en el financiamiento otorgado. Un diseño adecuado del programa contribuye a los dos objetivos del FMI: ayudar a los países miembros a solucionar sus problemas de balanza de pagos y que utilicen temporalmente los recursos del FMI.

CAPÍTULO 6

Anexo




Figura 6.1: Importancia de las características según su *Mean Decrease Accuracy*.




Figura 6.2: Importancia de las características según su *Mean Decrease Gini*.




Figura 6.3: Frecuencia de probabilidades de cumplimiento (0) e incumplimiento (1) de las metas para el set de test GRA-1 y umbral óptimo mínimo $t = 0,15$ (línea de puntos).




Figura 6.4: Frecuencia de probabilidades de cumplimiento (0) e incumplimiento (1) de las metas para el set de test GRA-4 y umbral óptimo mínimo $t = 0,28$ (línea de puntos).




Figura 6.5: Frecuencia de probabilidades de cumplimiento (0) e incumplimiento (1) de las metas para el set de test GRA-38 y umbral óptimo mínimo $t = 0,28$ (línea de puntos).




Figura 6.6: Shapley value descompuesto por sus principales características explicativas para el caso de la primera observación de Argentina. Status: 0. Probabilidad de incumplimiento: 0,378.




Figura 6.7: Shapley value descompuesto por sus principales características explicativas para el caso de la segunda observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.




Figura 6.8: Shapley value descompuesto por sus principales características explicativas para el caso de la tercera observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.

6. Anexo




Figura 6.9: Shapley value descompuesto por sus principales características explicativas para el caso de la cuarta observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.



Figura 6.10: Shapley value descompuesto por sus principales características explicativas para el caso de la quinta observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.




Figura 6.11: Shapley value descompuesto por sus principales características explicativas para el caso de la sexta observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.




Figura 6.12: Shapley value descompuesto por sus principales características explicativas para el caso de la séptima observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,378.



Figura 6.13: Shapley value descompuesto por sus principales características explicativas para el caso de la octava observación de Argentina. Status: 0. Probabilidad de incumplimiento: 0,144.




Figura 6.14: Shapley value descompuesto por sus principales características explicativas para el caso de la novena observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.

6. Anexo




Figura 6.15: Shapley value descompuesto por sus principales características explicativas para el caso de la decima observación de Argentina. Status: 1. Probabilidad de incumplimiento: 0,364.




Figura 6.16: Shapley value descompuesto por sus principales características explicativas para el caso de la decimoprimer observación de Argentina. Status: 0. Probabilidad de incumplimiento: 0,138.




Figura 6.17: Shapley value descompuesto por sus principales características explicativas para el caso de la decimosegunda observación de Argentina. Status: 0. Probabilidad de incumplimiento: 0,104.

Cuadro 6.1: Descripción de variables

Conteo total	Conteo subgrupo	Variable	Descripción
0	0	Status	Label: 0=meta cumplida; 1=meta no cumplida
1	1	Arrangement.Type_ECF	Tipo: 1=ECF; 0=otro
2	2	Arrangement.Type_ECF_EFF	Tipo: 1=ECF y EFF; 0=otro
3	3	Arrangement.Type_EFF	Tipo: 1=EFF; 0=otro
4	4	Arrangement.Type_ESF	Tipo: 1=ESF; 0=otro
5	5	Arrangement.Type_PCI	Tipo: 1=PCI; 0=otro
6	6	Arrangement.Type_PLL	Tipo: 1=PLL; 0=otro
7	7	Arrangement.Type_PRGF	Tipo: 1=PRGF; 0=otro
8	8	Arrangement.Type_PRGF_EFF	Tipo: 1=PRGF y EFF; 0=otro
9	9	Arrangement.Type_PSI	Tipo: 1=PSI; 0=otro
10	10	Arrangement.Type_SBA	Tipo: 1=SBA; 0=otro
11	11	Arrangement.Type_SBA_ESF	Tipo: 1=SBA y ESF; 0=otro
12	12	Arrangement.Type_SBA_SCF	Tipo: 1=SBA y SCF; 0=otro
13	13	Arrangement.Type_SCF	Tipo: 1=SCF; 0=otro
14	14	Precautionary	Programa precautorio: 1=sí; 0=no
15	1	Totalaccess	Monto total del programa (SDR)
16	2	Totalaccess_bxg	Monto total del programa / exportaciones (BXG) año previo inicio del programa (t-1)
17	1	Country.Code	ID del país (FMI)
18	2	Arrangement.Number	ID del programa (FMI)
19	1	T_3_PCPI_real	PCPI (Indice de Precios, promedio período) / ENDA (Tipo cambio nominal) en t-3
20	2	T_3_NGDP_usd	NGDP (Producto Bruto Interno) /END A en t-3
21	3	T_3_PCPIE_real	PCPIE (Indice de Precios, fin período)/END A en t-3
22	4	T_2_PCPI_real	PCPI/END A en t-2
23	5	T_2_NGDP_usd	NGDP/END A en t-2
24	6	T_2_PCPIE_real	PCPIE/END A en t-2
25	7	T_1_PCPI_real	PCPI/END A en t-1
26	8	T_1_NGDP_usd	NGDP/END A en t-1
27	9	T_1_PCPIE_real	PCPIE/END A en t-1
28	10	var_t_t_3_BMG	Var % BMG (Importaciones bienes) t-3 a t
29	11	var_t_t_3_BMS	Var % BMS (Importaciones servicios) t-3 a t
30	12	var_t_t_3_BXG	Var % BXG (Exportaciones bienes) t-3 a t
31	13	var_t_t_3_BXS	Var % BXS (Exportaciones servicios) t-3 a t
32	14	var_t_t_3_D	Var % D (Deuda externa bruta) t-3 a t
33	15	var_t_t_3_BFRA	Var % BFRA (Activos reserva) t-3 a t
34	16	var_t_t_3_BFD	Var % BFD (Inversión directa neta) t-3 a t
35	17	var_t_t_3_BF	Var % BF (Balance cta financiera) t-3 a t
36	18	var_t_t_3_BCA	Var % BCA (Balance cta corriente) t-3 a t
37	19	var_t_t_3_ENDA	Var % ENDA (Tipo cambio nominal) t-3 a t
38	20	var_t_t_3_NM	Var % NM (Importaciones bienes y servicios) t-3 a t

Continúa en la página siguiente

Tabla 6.2 – continuación

Conteo total	Conteo subgrupo	Variable	Descripción
39	21	var_t_t_3_BI	Var % BI (Ingreso neto) t-3 a t
40	22	var_t_t_3_PCPI	Var % PCPI (Precios consumidor, promedio período) t-3 a t
41	23	var_t_t_3_NX	Var % NX (Exportaciones bienes y servicios) t-3 a t
42	24	var_t_t_3_PCPIE	Var % PCPIE (Precios consumidor, fin período) t-3 a t
43	25	var_t_t_3_NCG	Var % NCG (Consumo público) t-3 a t
44	26	var_t_t_3_NCP	Var % NCP (Consumo privado) t-3 a t
45	27	var_t_t_3_BTR	Var % BTR (Transferencias corrientes netas) t-3 a t
46	28	var_t_t_3_NGS	Var % NGS (Ahorro nacional bruto) t-3 a t
47	29	var_t_t_3_FMB	Var % FMB (Oferta monetaria) t-3 a t
48	30	var_t_t_3_NGDP_R	Var % NGDP_R (PIB real) t-3 a t
49	31	var_t_t_3_NGDP	Var % NGDP (PIB nominal) t-3 a t
50	32	var_t_t_3_NFI	Var % NFI (Formación bruta capital fijo) t-3 a t
51	1	T_PCPI_real	PCPI/ENDA en año de inicio del programa (t)
52	2	T_NGDP_usd	NGDP/ENDA en t
53	3	T_PCPIE_real	PCPIE/ENDA en t
54	4	TX1_PCPI_real	PCPI/ENDA en t+1
55	5	TX1_NGDP_usd	NGDP/ENDA en t+1
56	6	TX1_PCPIE_real	PCPIE/ENDA en t+1
57	7	TX2_PCPI_real	PCPI/ENDA en t+2
58	8	TX2_NGDP_usd	NGDP/ENDA en t+2
59	9	TX2_PCPIE_real	PCPIE/ENDA en t+2
60	10	TX3_PCPI_real	PCPI/ENDA en t+3
61	11	TX3_NGDP_usd	NGDP/ENDA en t+3
62	12	TX3_PCPIE_real	PCPIE/ENDA en t+3
63	13	TX4_PCPI_real	PCPI/ENDA en t+4
64	14	TX4_NGDP_usd	NGDP/ENDA en t+4
65	15	TX4_PCPIE_real	PCPIE/ENDA en t+4
66	16	var_t4_t_BMG	Var % esperada BMG t a t+4
67	17	var_t4_t_BMS	Var % esperada BMS t a t+4
68	18	var_t4_t_BXG	Var % esperada BXG t a t+4
69	19	var_t4_t_BXS	Var % esperada BXS t a t+4
70	20	var_t4_t_D	Var % esperada D t a t+4
71	21	var_t4_t_BFRA	Var % esperada BFRA t a t+4
72	22	var_t4_t_BFD	Var % esperada BFD t a t+4
73	23	var_t4_t_BF	Var % esperada BF t a t+4
74	24	var_t4_t_BCA	Var % esperada BCA t a t+4
75	25	var_t4_t_NM	Var % esperada NM t a t+4
76	26	var_t4_t_BI	Var % esperada BI t a t+4
77	27	var_t4_t_PCPI	Var % esperada PCPI t a t+4
78	28	var_t4_t_NX	Var % esperada NX t a t+4
79	29	var_t4_t_PCPIE	Var % esperada PCPIE t a t+4
80	30	var_t4_t_NCG	Var % esperada NCG t a t+4
81	31	var_t4_t_NCP	Var % esperada NCP t a t+4
82	32	var_t4_t_BTR	Var % esperada BTR t a t+4
83	33	var_t4_t_NGS	Var % esperada NGS t a t+4
84	34	var_t4_t_NGDP_R	Var % esperada NGDP_R t a t+4

Continúa en la página siguiente

Tabla 6.2 – continuación

Conteo total	Conteo subgrupo	Variable	Descripción
85	35	var_t4_t_NGDP	Var % esperada NGDP t a t+4
86	36	var_t4_t_NFI	Var % esperada NFI t a t+4
87	1	Fycy_CY	Registro contable : 1=Año calendario; 0=otro
88	2	Fycy_FY	Registro contable: 1=Año fiscal; 0=otro
89	1	R	Número de revisión (1 a 13)
90	1	QPC_date_span	Días entre inicio programa y revisión de meta
91	2	Purchase_date_span	Días entre inicio programa y desembolso
92	1	Purchase_Original_Amount	Monto originalmente planeado a desembolsar en la revisión (Purchase)
93	2	Purchase_Original_Amount_ENDA_1	Purchase/ENDA en t-1
94	3	Purchase_Original_Amount_ENDA_2	Purchase/ENDA en t-2
95	4	Purchase_Original_Amount_ENDA_3	Purchase/ENDA en t-3
96	5	Purchase_Original_Amount_ENDA_t	Purchase/ENDA en t
97	6	Purchase_Original_Amount_ENDAX1	Purchase/ENDA en t+1
98	7	Purchase_Original_Amount_ENDAX2	Purchase/ENDA en t+2
99	8	Purchase_Original_Amount_ENDAX3	Purchase/ENDA en t+3
100	9	Purchase_Original_Amount_ENDAX4	Purchase/ENDA en t+4
101	10	Purchaseschedule_Original	Fecha del desembolso: 1=original; 0=otra
102	11	Purchaseschedule_Revised	Fecha del desembolso: 1=revisada; 0=otra
103	12	Purchaseschedule_NA	Fecha del desembolso: 1=sin dato; 0=otra
104	1	QPC_Original_Amount	Monto original de la meta (QPC) en billones USD, SDR o moneda nacional
105	2	QPC_Original_Amount_real	QPC/BXG (si QPC en USD o SDR) o QPC/NGDP (si QPC en moneda nacional)
106	3	QPC_Original_Amount_ENDA_1	QPC/ENDA en t-1
107	4	QPC_Original_Amount_ENDA_2	QPC/ENDA en t-2
108	5	QPC_Original_Amount_ENDA_3	QPC/ENDA en t-3
109	6	QPC_Original_Amount_ENDA_t	QPC/ENDA en t
110	7	QPC_Original_Amount_ENDAX1	QPC/ENDA en t+1
111	8	QPC_Original_Amount_ENDAX2	QPC/ENDA en t+2
112	9	QPC_Original_Amount_ENDAX3	QPC/ENDA en t+3
113	10	QPC_Original_Amount_ENDAX4	QPC/ENDA en t+4
114	1	Units_USD_bill	Unidad del QPC: 1=USD billones; 0=otro
115	2	Units_USD_mill	Unidad del QPC: 1=USD millones; 0=otro
116	3	Units_NC_bill	Unidad del QPC: 1=moneda nacional billones; 0=otro
117	4	Units_NC_mill	Unidad del QPC: 1=moneda nacional millones; 0=otro
118	5	Units_SDR_mill	Unidad del QPC: 1=SDR millones; 0=otro
119	1	Sesgo	Sesgo esperado distribución variable target del QPC: -1=baja; 1=alza

Bibliografía

- [1] Breiman, L. (1984). Classification and regression trees. *Routledge*.
- [2] Breiman, L. (2001). Random forests. *Machine learning*, 45:5–32..
- [3] Burman, P., Chow, E., & Nolan, D. (1994). A cross-validatory method for dependent data. *Biometrika*, 81(2), 351–358.
- [4] Efron, B. (1979). Bootstrap methods: another look at the jackknife. In Breakthroughs in statistics: Methodology and distribution, pages 569–593. *Springer*.
- [5] European Central Bank (2019). Conditionality and design of IMF-supported programmes. *ECB Occasional Paper Series No 235*.
- [6] Fortmann-Roe, S. (2012). Understanding the bias-variance tradeoff. Disponible online.
- [7] International Monetary Fund (2018). Argentina. Ex-post evaluation of exceptional access under the 2018 stand-by arrangement. IMF Country Report No. 21/279. *International Monetary Fund*.
- [8] International Monetary Fund (2019). Weekly Report on Key Financial Statistics as of December 26, 2019. *International Monetary Fund*.
- [9] International Monetary Fund (2020). Articles of agreement of the International Monetary Fund. *International Monetary Fund*.
- [10] International Monetary Fund (2023). Changes to the Fund’s financing assurances policy in the context of Fund Upper Credit Tranche (UCT) financing under exceptionally high uncertainty. *International Monetary Fund*.
- [11] International Monetary Fund (2025). Weekly Report on Key Financial Statistics as of December 19, 2025. *International Monetary Fund*.
- [12] International Monetary Fund - Independent Evaluation Office (2008). Structural Conditionality in IMF-Supported Programs. *International Monetary Fund*.
- [13] International Monetary Fund - Strategy, Policy, & Review Department (2021). How to Assess Country Risk: The Vulnerability Exercise Approach Using Machine Learning. *International Monetary Fund*.
- [14] International Monetary Fund - Strategy, Policy, & Review Department (2025). The Global Financial Safety Net—A Stocktaking. *International Monetary Fund*.

- [15] Iseringhausen, M., Mwanza Nkusu, and Wellian Wiranto (2019). Repeated Use of IMF-Supported Programs: Determinants and Forecasting. *IMF Working Papers*.
- [16] Shapley, L. S. (1953). A value for n -person games. *Princeton University Press*.
- [17] Tibshirani, R. J. and Efron, B. (1993). An introduction to the bootstrap. *Monographs on statistics and applied probability*, 57(1).
- [18] Tibshirani, R., Hastie, T., , Friedman, J. H., and Friedman, J. H. (2009). The elements of statistical learning: data mining, inference, and prediction, Volume 2. *Springer*.
- [19] Tsendsuren Batsuuri, Shan He, Ruofei Hu, Jonathan Leslie, and Flora Lutz (2024). Predicting IMF-Supported Programs: A Machine Learning Approach. *IMF Working Papers 2024*, 054.